

Kecerdasan Artifisial dalam Otomatisasi DevOps: Tinjauan Literatur Sistematis tentang Aplikasi, Manfaat, Tantangan, dan Tren Penelitian dari 2016 hingga 2026

Abstrak

Kecerdasan Artifisial (AI) semakin diterapkan pada DevOps untuk meningkatkan otomatisasi, pemantauan, pengujian, manajemen insiden, dukungan keputusan operasional, dan remediasi. Namun, literatur masih terfragmentasi berdasarkan tahapan DevOps, teknik AI, lingkungan evaluasi, dan tingkat kematangan empiris. Studi ini menyajikan Tinjauan Literatur Sistematis (SLR) tentang Kecerdasan Artifisial untuk Otomatisasi DevOps yang mencakup periode 2016–2026. Tinjauan mengikuti panduan tinjauan sistematis untuk rekayasa perangkat lunak, menggunakan PICOC untuk menyusun ruang lingkup tinjauan dan strategi pencarian, serta menerapkan PRISMA 2020 untuk pelaporan seleksi studi. Pencarian dilakukan pada ScienceDirect, IEEE Xplore, dan ACM Digital Library, dan mengidentifikasi 1.132 rekaman. Setelah penghapusan, deduplikasi, penyaringan, pengambilan, dan penilaian kelayakan, 60 studi primer disertakan dan dianalisis menggunakan skema ekstraksi 26-field, meskipun masih terdapat keterbatasan substansial dalam pengambilan teks lengkap.

Hasil menunjukkan bahwa aktivitas penelitian semakin terkonsentrasi pada 2024–2026 dan berkembang dari pendekatan yang terutama bersifat prediktif dan diagnostik menuju AI Generatif, Large Language Model, dan sistem agentik yang mulai berkembang. Aplikasi AI terutama terkonsentrasi pada pemantauan dan observabilitas, operasi, serta aktivitas insiden/analisis akar penyebab/remediasi. Machine Learning Klasik tetap menjadi kategori AI primer yang dominan, sementara pendekatan AI Generatif/LLM dan Agentik/Multi-Agen membentuk segmen metodologis yang sedang berkembang. Manfaat yang dilaporkan mencakup peningkatan kecepatan dan efisiensi, kualitas deteksi, keandalan, optimasi sumber daya, otomatisasi, keamanan, dan dukungan keputusan manusia. Namun, kekuatan bukti sangat bervariasi pada lingkungan produksi, empiris industri, eksperimen terkontrol, benchmark, simulasi, dan konseptual.

Tinjauan ini juga mengidentifikasi tantangan berulang terkait kualitas data, kemampuan generalisasi, concept drift, realisme evaluasi, explainability, keandalan LLM, biaya, kompleksitas integrasi, keamanan remediasi otonom, pengawasan manusia, keamanan, privasi, dan inkonsistensi evaluasi. Temuan tersebut disintesis menjadi delapan kesenjangan penelitian dan lima arah penelitian masa depan. Secara keseluruhan, literatur menunjukkan lintasan dari Prediktif → Diagnostik → Generatif → Agentik → DevOps Otonom yang Tepercaya, sekaligus menunjukkan bahwa kapabilitas teknis berkembang lebih cepat daripada manfaat produksi yang telah dibuktikan. Oleh karena itu, kemajuan masa depan bergantung pada penutupan kesenjangan antara kelayakan teknis dan DevOps berbasis AI yang aman, andal, dapat dijelaskan, hemat biaya, dan tervalidasi di lingkungan produksi.

Kata Kunci: Kecerdasan Artifisial, DevOps, AIOps, AI Generatif, Large Language Model, Agen AI, Otomatisasi DevOps, Tinjauan Literatur Sistematis

1. Pendahuluan

DevOps telah menjadi pendekatan rekayasa perangkat lunak yang diadopsi secara luas untuk mengintegrasikan aktivitas pengembangan dan operasi melalui integrasi berkelanjutan, delivery berkelanjutan, otomatisasi, pemantauan, dan umpan balik cepat. Adopsinya bertujuan memperpendek siklus delivery sekaligus mempertahankan kualitas perangkat lunak, keandalan, dan responsivitas operasional [1]. Namun, ketika sistem perangkat lunak menjadi semakin terdistribusi, cloud-native, dan terus berkembang, tim DevOps harus memproses volume besar telemetri operasional, informasi build dan deployment, laporan insiden, log, trace, metrik, dan data konfigurasi.

Kecerdasan Artifisial (AI) semakin diperkenalkan ke dalam lingkungan operasional ini untuk mendukung atau mengotomatisasi tugas yang sulit dilakukan secara manual pada skala besar. Penelitian awal terutama menekankan prediksi berbasis machine learning, deteksi anomali, manajemen kegagalan, dan analitik operasional, yang sering dibahas dalam paradigma AIOps yang lebih luas [2]. Penelitian yang lebih baru memperluas arah ini melalui Large Language Model (LLM), yang memungkinkan penalaran bahasa alami atas data insiden, log, dokumentasi, dan

pengetahuan operasional [3], [4]. Pendekatan agentik yang mulai berkembang selanjutnya menggabungkan penalaran LLM dengan alat, workflow, dan mekanisme eksekusi, meskipun sistem ini masih merupakan arah penelitian tahap awal yang sensitif terhadap aspek keselamatan, bukan tingkat kematangan industri yang telah mapan [5].

Meskipun volume penelitian terus bertambah, literatur AI-for-DevOps masih heterogen. Studi berbeda secara substansial dalam aktivitas DevOps yang ditangani, metode AI yang digunakan, dataset dan lingkungan operasional yang dipakai untuk evaluasi, manfaat yang dilaporkan, serta kekuatan bukti yang mendukung manfaat tersebut. Penelitian yang ada juga mencakup analitik prediktif, AIOps diagnostik, pendekatan generatif, dan sistem yang semakin agentik, sehingga sulit memperoleh pandangan terpadu mengenai bagaimana bidang ini berkembang dan di mana bukti yang andal saat ini tersedia.

Tinjauan ini karena itu secara khusus berfokus pada AI-for-DevOps: penelitian yang menggunakan AI untuk meningkatkan, mendukung, atau mengotomatisasi aktivitas DevOps. Studi yang secara eksklusif membahas MLOps atau DevOps-for-AI berada di luar batas tinjauan. Tinjauan mencakup periode 2016–2026 dan menyintesis bukti dari ScienceDirect, IEEE Xplore, dan ACM Digital Library dengan menggunakan panduan tinjauan sistematis bergaya Kitchenham dan Charters, PICOC, serta pelaporan PRISMA 2020.

Pencarian mengidentifikasi 1.132 rekaman. Setelah dua rekaman non-artikel/container dihapus sebelum penyaringan dan 317 kemunculan duplikat dihapus, 813 rekaman unik disaring berdasarkan judul dan abstrak. Sebanyak 382 laporan dicari untuk diambil; 73 teks lengkap berhasil diperoleh dan dinilai, 13 dikeluarkan pada tahap teks lengkap, dan 60 studi primer disertakan dalam korpus akhir.

SLR ini memberikan lima kontribusi. Pertama, mengkarakterisasi tren penelitian AI-for-DevOps antara 2016 dan 2026. Kedua, memetakan aplikasi AI ke tahapan dan aktivitas DevOps. Ketiga, mengembangkan taksonomi tujuh kategori untuk metode dan teknologi AI yang digunakan dalam korpus. Keempat, menyintesis manfaat yang dilaporkan dengan secara eksplisit membedakan kekuatan bukti pendukung. Kelima, mengonsolidasikan tantangan berulang, kesenjangan penelitian, dan arah penelitian masa depan menuju DevOps berbasis AI yang tepercaya.

Dengan demikian, tinjauan ini membahas lima pertanyaan penelitian: RQ1 mengkaji tren penelitian dari waktu ke waktu; RQ2 mengidentifikasi tahapan dan aktivitas DevOps tempat AI diterapkan; RQ3 menganalisis metode dan teknologi AI yang digunakan; RQ4 menyintesis manfaat dan dampak yang dilaporkan; dan RQ5 mengkaji tantangan, keterbatasan, kesenjangan penelitian, dan peluang masa depan.

Secara keseluruhan, tinjauan ini menafsirkan literatur sebagai pergerakan dari AI prediktif dan diagnostik menuju pendekatan generatif dan agentik. Lintasan ini tidak boleh ditafsirkan sebagai bukti bahwa DevOps otonom sudah siap untuk lingkungan produksi. Sebaliknya, lintasan tersebut memotivasi arah penelitian jangka panjang menuju DevOps otonom yang tepercaya, yaitu kapabilitas yang diimbangi oleh keandalan, keselamatan, bukti, tata kelola, dan pengawasan manusia.

Sisa artikel ini disusun sebagai berikut. Bagian 2 menyajikan latar belakang konseptual dan batas ruang lingkup. Bagian 3 menjelaskan metodologi tinjauan. Bagian 4 melaporkan hasil untuk RQ1–RQ5. Bagian 5 membahas implikasi hasil tersebut. Bagian 6 membahas ancaman terhadap validitas, dan Bagian 7 menyimpulkan tinjauan.

2. Latar Belakang

2.1 DevOps dan Otomatisasi DevOps

DevOps mengintegrasikan pengembangan dan operasi melalui praktik kolaboratif, otomatisasi, integrasi dan delivery berkelanjutan, pemantauan, umpan balik, serta tanggung jawab bersama atas delivery dan operasi perangkat lunak [1]. Otomatisasi merupakan inti model ini karena workflow build, pengujian, deployment, pemantauan, dan operasional yang dapat diulang mengurangi upaya manual dan memungkinkan umpan balik yang lebih cepat.

Dalam tinjauan ini, dibedakan antara otomatisasi prosedural dan otomatisasi cerdas. Otomatisasi prosedural mengikuti aturan atau workflow yang telah ditentukan, sedangkan otomatisasi cerdas memperkenalkan inferensi berbasis data, prediksi, diagnosis, rekomendasi, atau tindakan. DevOps berbasis AI dengan demikian memperluas otomatisasi konvensional dengan memungkinkan sistem menafsirkan bukti operasional dan menyesuaikan keputusan terhadap konteks.

2.2 Kecerdasan Artifisial dan AIOps dalam DevOps

Teknik AI yang digunakan dalam DevOps mencakup machine learning klasik, deep learning, pendekatan berorientasi anomali atau tanpa pengawasan, optimasi dan reinforcement learning, metode bahasa alami dan pembelajaran representasi, AI Generatif dan LLM, serta pendekatan agentik atau multi-agen yang mulai berkembang. Teknik-teknik ini diterapkan pada tugas seperti deteksi anomali, prediksi kegagalan, optimasi pengujian, manajemen sumber daya, analisis akar penyebab, triase insiden, dukungan remediasi, dan pengambilan keputusan operasional.

AIOps diperlakukan dalam tinjauan ini sebagai paradigma aplikasi, bukan kategori algoritmik tersendiri. Istilah tersebut menggambarkan penerapan analitik dan AI pada operasi TI dan manajemen kegagalan, sedangkan metode yang mendasarinya dapat termasuk ke dalam beberapa keluarga AI [2]. Pembedaan ini penting untuk menghindari pencampuran antara domain operasional dan metode teknis tertentu.

2.3 AI Generatif, LLM, dan DevOps Agentik

AI Generatif dan LLM memperluas AI-for-DevOps dengan memungkinkan penalaran atas artefak operasional tidak terstruktur seperti log, tiket, runbook, dokumentasi, kode, dan narasi insiden. Contohnya mencakup rekomendasi akar penyebab dan langkah mitigasi untuk insiden cloud [3] serta penerapan LLM yang lebih luas dalam rekayasa perangkat lunak [4].

Sistem agentik memperluas penalaran berbasis LLM dengan mengintegrasikan perencanaan, penggunaan alat, eksekusi, umpan balik, dan koordinasi multi-agen. Dalam konteks DevOps, hal ini dapat memungkinkan sistem tidak hanya menjelaskan atau merekomendasikan tindakan, tetapi juga memanggil alat dan menjalankan langkah operasional yang dibatasi. Karena tindakan operasional dapat memengaruhi ketersediaan, biaya, keamanan, dan integritas data, DevOps agentik memerlukan izin eksplisit, verifikasi bukti, auditabilitas, rollback, pengawasan manusia, dan mekanisme eskalasi yang aman [5].

Untuk tujuan sintesis, tinjauan ini menggunakan lensa fungsional Bantu → Prediksi → Diagnosis → Rekomendasi → Tindakan. Ini merupakan lensa konseptual tingkat tinjauan untuk membandingkan bentuk otomatisasi dan tidak boleh ditafsirkan sebagai model kematangan eksternal yang diterima secara universal.

2.4 Batas Ruang Lingkup: AI-for-DevOps versus MLOps dan DevOps-for-AI

Batas tinjauan ditentukan berdasarkan arah intervensi. AI-for-DevOps mengacu pada penggunaan AI untuk meningkatkan proses DevOps, misalnya dengan mengotomatisasi pengujian, pemantauan, diagnosis, penanganan insiden, optimasi sumber daya, atau dukungan keputusan operasional. Sebaliknya, DevOps-for-AI dan MLOps menggunakan prinsip serta infrastruktur DevOps untuk mengelola siklus hidup sistem AI/ML [6].

Karena beberapa studi menggabungkan kedua arah tersebut, kasus yang berada di batas dinilai berdasarkan tujuan penelitian utama dan proses operasional yang ditingkatkan. Studi yang secara eksklusif berfokus pada pengembangan, deployment, atau tata kelola model AI dikeluarkan kecuali AI juga digunakan untuk meningkatkan suatu aktivitas DevOps.

2.5 Kerangka Konseptual Tinjauan

Kerangka konseptual menghubungkan lima pertanyaan penelitian sebagai berikut: Evolusi Penelitian (RQ1) → Tahap/Aktivitas DevOps (RQ2) → Metode/Teknologi AI (RQ3) → Manfaat dan Kekuatan Bukti (RQ4) → Tantangan dan Keterbatasan (RQ5) → Kesenjangan Penelitian dan Arah Masa Depan.

Struktur ini memisahkan apa yang diotomatisasi, bagaimana AI diterapkan, manfaat apa yang dilaporkan, dan seberapa kuat manfaat tersebut didukung. Struktur ini juga mendukung sintesis yang lebih luas mengenai evolusi teknologi dari prediksi yang berpusat pada model menuju analitik terintegrasi pipeline, sistem penalaran, dan sistem agentik yang mulai berkembang. Lintasan ini merupakan sintesis interpretatif dari literatur yang ditinjau, bukan model kematangan kausal atau berurutan secara universal.

3. Metodologi Penelitian

3.1 Protokol Tinjauan dan Pertanyaan Penelitian

SLR ini mengikuti panduan tinjauan sistematis yang mapan untuk rekayasa perangkat lunak, menggunakan PICOC untuk menyusun ruang lingkup dan proses pencarian serta PRISMA 2020 untuk melaporkan seleksi studi. Ruang lingkup tinjauan dibatasi pada penelitian AI-for-DevOps yang dipublikasikan dari 2016 hingga 2026. Pencarian database final dilakukan pada 7 September 2026.

Lima pertanyaan penelitian didefinisikan untuk mencakup tren temporal (RQ1), tahapan dan aktivitas DevOps (RQ2), metode dan teknologi AI (RQ3), manfaat dan dampak (RQ4), serta tantangan, keterbatasan, dan peluang masa depan (RQ5). Sintesis menggabungkan analisis kuantitatif deskriptif dengan sintesis tematik kualitatif; tidak dilakukan meta-analisis statistik.

3.2 PICOC dan Strategi Pencarian

Tabel 1. Kerangka PICOC yang Digunakan dalam Tinjauan

Elemen PICOC	Definisi Operasional
Populasi	Praktik, proses, pipeline, CI/CD, dan delivery perangkat lunak DevOps.
Intervensi	Kecerdasan Artifisial, Machine Learning, Deep Learning, AI Generatif, Large Language Model, dan AIOps.
Perbandingan	Pendekatan DevOps tradisional atau non-AI, jika tersedia; perbandingan tidak diwajibkan untuk inklusi.
Hasil	Otomatisasi, efisiensi, keandalan, kualitas perangkat lunak, kinerja deployment, penyelesaian insiden, dan hasil operasional terkait.
Konteks	Rekayasa perangkat lunak, pengembangan perangkat lunak, dan operasi perangkat lunak.

Tinjauan final menggunakan log pencarian operasional yang dipertahankan untuk ketiga database, alih-alih secara retroaktif menyajikan string Boolean awal sebagai query yang dieksekusi secara tepat. Pencarian ScienceDirect terdiri atas DevOps + AI (48), CI/CD + AI (28), continuous integration + AI (50), continuous delivery + AI (11), continuous deployment + AI (12), software delivery + AI (3), dan AIOps (33), dengan total 185 rekaman. Pencarian IEEE Xplore yang bersesuaian menghasilkan 179, 129, 159, 38, 53, 23, dan 184 rekaman, dengan total 765.


ACM Digital Library menghasilkan 182 rekaman; dua rekaman proceedings/container dihapus sebelum penyaringan, sehingga tersisa 180 rekaman artikel. Sintaks query tekstual ACM spesifik-platform yang tepat tidak dipertahankan dalam rekaman tinjauan yang tersedia. String Boolean awal memang ada selama pengembangan protokol, tetapi tidak diperlakukan sebagai query final yang dieksekusi secara tepat. Scopus Preview dipertimbangkan selama pengembangan protokol, tetapi bukan bagian dari kumpulan database primer final.

3.3 Seleksi Studi dan Proses PRISMA

Pencarian mengidentifikasi 1.132 rekaman: 185 dari ScienceDirect, 765 dari IEEE Xplore, dan 180 rekaman artikel ACM setelah menghapus dua rekaman container/proceedings. Dengan demikian, 1.130 rekaman masuk ke deduplikasi. Sebanyak 317 kemunculan duplikat dihapus, menyisakan 813 rekaman unik untuk penyaringan judul dan abstrak.

Penyaringan judul dan abstrak mengecualikan 431 rekaman, menyisakan 382 laporan yang dicari untuk diambil. Upaya pengambilan dilakukan untuk seluruh 382 laporan melalui workflow tinjauan. Tujuh puluh tiga teks lengkap berhasil diperoleh dan dinilai, sedangkan 309 laporan tidak berhasil diambil. Tiga belas dari 73 laporan yang dinilai dikeluarkan pada tahap teks lengkap, sehingga tersisa 60 studi primer yang disertakan. Alasan eksklusi final adalah FT3=2, FT4=1, FT5=7, dan FT6=3.

Dengan demikian, perhitungan PRISMA final adalah: 1.132 teridentifikasi → 1.130 masuk deduplikasi → 813 unik disaring → 382 laporan dicari → 73 diambil dan dinilai → 60 disertakan. Tidak ada keputusan teks lengkap yang masih tertunda.



Gambar 1. Diagram alir PRISMA 2020 untuk proses seleksi studi.

3.4 Penilaian Kualitas

Seluruh 60 studi yang disertakan menjalani penilaian kualitas menggunakan lima kriteria: QA1, kejelasan tujuan penelitian; QA2, kejelasan hubungan DevOps dan AI; QA3, kecukupan metode penelitian atau evaluasi; QA4, dukungan bukti terhadap hasil yang dilaporkan; dan QA5, pelaporan keterbatasan, ancaman, atau implikasi.

Sebuah studi dinyatakan lulus apabila memperoleh setidaknya 3,0 dari 5. Seluruh 60 studi yang disertakan melewati ambang tersebut. QA PASS hanya digunakan sebagai gerbang kualitas minimum dan tidak ditafsirkan sebagai bukti bahwa semua studi memiliki kekuatan empiris yang sama.

3.5 Ekstraksi Data

Ekstraksi data diselesaikan untuk seluruh 60 studi menggunakan skema 26-field: Paper ID, Authors, Year, Title, Source Database, Venue, Publication Type, Research Type, DevOps Stage, DevOps Activity, AI Category, AI Method/Model, Dataset/System, Research Objective, Evaluation Method, Metrics, Main Findings, Benefits, Challenges, Limitations, Future Work, RQ Mapping, QA Score, Industrial Context, Evidence Type, dan Evidence Strength.

Main Findings, Benefits, Challenges, Limitations, dan Future Work dipertahankan sebagai bukti yang berasal dari paper. DevOps Stage, AI Category, RQ Mapping, dan Evidence Strength diperlakukan sebagai pengodean tingkat tinjauan. Evidence Strength diklasifikasikan sebagai Production, Industrial Empirical, Controlled Experimental, Benchmark, Simulation, atau Conceptual.

3.6 Sintesis dan Analisis Data

RQ1 dianalisis melalui hitungan deskriptif tahunan dan interpretasi kualitatif terhadap tren teknologi. RQ2 menggunakan pengodean multi-label karena sebuah studi dapat membahas beberapa tahapan atau aktivitas DevOps; oleh karena itu, persentase RQ2 tidak diharapkan berjumlah 100%. RQ3 menggunakan taksonomi tujuh kategori dan kategori primer yang saling eksklusif untuk distribusi kuantitatif.

RQ4 menyintesis tujuh tema manfaat. Karena frekuensi B1–B7 yang dapat direproduksi untuk seluruh korpus tidak tersedia, tema manfaat tidak diperingkat secara statistik; sebagai gantinya digunakan jangkar bukti representatif. RQ5 menyintesis empat belas tema tantangan, delapan kesenjangan penelitian (G1–G8), dan lima arah penelitian masa depan (FR1–FR5), juga tanpa mengada-adakan frekuensi prevalensi seluruh korpus.

Interpretasi mempertimbangkan kekuatan bukti. Hasil benchmark atau eksperimen terkontrol tidak diperlakukan setara dengan dampak produksi, metrik prediktif yang lebih tinggi tidak diasumsikan berarti MTTR yang lebih rendah, dan sistem agentik yang sedang berkembang tidak dikarakterisasi sebagai siap produksi secara luas.

4. Hasil

4.1 Seleksi Studi dan Gambaran Umum Korpus

Korpus final terdiri atas 60 studi primer yang dipublikasikan antara 2019 dan 2026. Tidak ada studi yang disertakan dari tahun 2016–2018. Korpus mencakup deployment produksi, studi empiris industri, eksperimen terkontrol, benchmark, simulasi, serta pekerjaan arsitektural konseptual atau terapan.

Distribusi publikasi terkonsentrasi pada tahun-tahun akhir periode tinjauan, dengan lebih dari separuh studi yang disertakan muncul pada 2024–2026. Konsentrasi ini konsisten dengan ekspansi pesat pendekatan berbasis LLM dan agentik yang mulai berkembang dalam beberapa tahun terakhir.

4.2 RQ1 — Tren Penelitian dari 2016 hingga 2026

Tabel 2. Distribusi Tahunan Studi yang Disertakan

Tahun	Studi
2016	0
2017	0

Tahun	Studi
2018	0
2019	3
2020	7
2021	4
2022	7
2023	7
2024	12
2025	8
2026	12

Distribusi tahunan final adalah 2019=3, 2020=7, 2021=4, 2022=7, 2023=7, 2024=12, 2025=8, dan 2026=12. Studi [7] ditempatkan pada 2026 berdasarkan publikasi bibliografis akhirnya di IEEE Internet of Things Journal, sedangkan tanggal 2025 merujuk pada rekaman publikasi online/DOI yang lebih awal. Koreksi ini tidak mengubah total korpus sebanyak 60 studi.

Sepanjang periode tersebut, literatur berkembang dari AI yang terutama prediktif menuju AIOps diagnostik, diikuti AI Generatif dan pendekatan agentik yang mulai berkembang. Hasil ini menggambarkan lintasan penelitian yang dapat diamati; interpretasi arsitektural yang lebih mendalam dibahas pada Bagian 5.

4.3 RQ2 — Aplikasi AI pada Tahapan dan Aktivitas DevOps

Tabel 3. Distribusi Aplikasi AI pada Tahapan dan Aktivitas DevOps

Tahap / Aktivitas DevOps	Studi	Persentase
Pemantauan / Observabilitas	35	58.3%
Operasi	31	51.7%
Insiden / RCA / Remediasi	17	28.3%
Pengujian	16	26.7%
Build / CI	10	16.7%
Deployment / Rilis	9	15.0%
Pengembangan / Kode / IaC	3	5.0%
Tata Kelola Model AIOps	3	5.0%
Manusia / Lintas-Aspek	1	1.7%


RQ2 menggunakan pengodean multi-label, sehingga persentasenya tidak berjumlah 100%. Konsentrasi terbesar terdapat pada pemantauan/observabilitas dan operasi, diikuti insiden, analisis akar penyebab, dan remediasi. Pengujian, build/CI, dan deployment juga mendapat perhatian substansial, sedangkan pengembangan/kode/IaC serta studi yang secara eksplisit berorientasi manusia atau tata kelola lebih jarang.

4.4 RQ3 — Metode dan Teknologi AI


Tabel 4. Distribusi Kategori AI Primer

Kategori AI Primer	Studi	Persentase
Machine Learning Klasik	27	45.0%
Deep Learning	8	13.3%
AI Generatif / LLM	7	11.7%
AI Tanpa Pengawasan / Anomali	6	10.0%
AI Agentik / Multi-Agen	5	8.3%
NLP / Pembelajaran Representasi	4	6.7%
Optimasi & Reinforcement Learning	3	5.0%


Machine Learning Klasik tetap menjadi kategori primer yang dominan. Pada saat yang sama, korpus mencakup ragam metodologis yang semakin luas, meliputi Deep Learning, teknik berorientasi anomali, NLP dan pembelajaran representasi, optimasi dan reinforcement learning, AI Generatif/LLM, serta sistem Agentik/Multi-Agen yang mulai berkembang. AIOps tidak dihitung sebagai kategori algoritmik tersendiri.



Gambar 2. Tren publikasi RQ1.



Gambar 3. Distribusi aktivitas DevOps RQ2 (multi-label).



Gambar 4. Distribusi kategori AI primer RQ3.

4.5 RQ4 – Manfaat dan Dampak

Sintesis kualitatif mengidentifikasi tujuh tema manfaat: B1 Kecepatan & Efisiensi; B2 Akurasi & Kualitas Deteksi; B3 Keandalan & Ketersediaan; B4 Optimasi Biaya & Sumber Daya; B5 Otomatisasi & Pengurangan Toil; B6 Peningkatan Keamanan; dan B7 Dukungan Keputusan Manusia & Produktivitas.

Tema-tema ini merangkum jenis manfaat yang dilaporkan dalam korpus. Tema tersebut bukan peringkat prevalensi seluruh korpus karena frekuensi yang dapat direproduksi untuk seluruh 60 studi tidak tersedia. Jangkar bukti representatif mencakup studi produksi seperti [8] (Predictive Test Selection), [9] (prediksi kegagalan node Alibaba), dan [10] (DeCaf); studi empiris industri seperti [11] (analisis akar penyebab GPT-4) dan [12] (prioritisasi log berbasis LLM); serta bukti benchmark seperti [13] (RCA multi-agen dengan augmentasi graf).

4.6 RQ5 – Tantangan, Keterbatasan, dan Peluang Masa Depan

Empat belas tema tantangan berulang diidentifikasi: Kualitas & Ketersediaan Data; Ketidakseimbangan Kelas; Kebocoran Data & Evaluasi Tidak Realistik; Concept Drift & Penurunan Model; Generalisasi Terbatas; Kesenjangan Benchmark-ke-Produksi; Explainability & Kepercayaan; Halusinasi & Keandalan LLM; Biaya/Latensi/Konsumsi Sumber Daya; Kompleksitas Integrasi; Keamanan Remediasi Otonom; Human-in-the-Loop; Keamanan & Privasi; dan Inkonsistensi Metrik Evaluasi.

Tantangan tersebut disintesis menjadi delapan kesenjangan penelitian: G1 Validasi Skala Produksi; G2 Generalisasi Lintas Sistem; G3 Concept Drift & Pemeliharaan Jangka Panjang; G4 Explainability, Kepercayaan & Keandalan; G5 Keamanan Remediasi Otonom; G6 Biaya & Latensi LLM/Agen; G7 Kolaborasi & Adopsi Manusia-AI; dan G8 Evaluasi Operasional Terpadu ML + DevOps.

Kesenjangan tersebut selanjutnya dikonsolidasikan menjadi lima arah penelitian masa depan: FR1 AI-for-DevOps yang Tervalidasi di Produksi; FR2 AIOps yang Adaptif dan Dapat Digeneralisasi; FR3 LLM-AIOps yang Terpercaya dan Dapat Dijelaskan; FR4 DevOps Agentik yang Aman dan Efisien Biaya; dan FR5 DevOps Otonom yang Berpusat pada Manusia. Tidak ada frekuensi tantangan seluruh korpus yang dilaporkan.

Untuk kelengkapan, Tabel 5 merangkum seluruh 60 studi primer yang disertakan beserta pengodean yang digunakan dalam sintesis.

Tabel 5. Gambaran Umum 60 Studi Primer yang Disertakan

Catatan: pengenalan PS menunjukkan ID studi primer yang digunakan selama seleksi studi dan ekstraksi data; angka dalam tanda kurung siku menunjukkan referensi IEEE yang bersesuaian.

PS ID	Sitasi	Tahun	Judul	Tahap DevOps	Kategori AI	Kekuatan Bukti
PS001	[14]	2025	Research on Big Data Analysis and Anomaly Detection Algorithms in Intelligent Operations and Maintenance	Pemantauan; Operasi	Deep Learning	Eksperimen Terkontrol
PS002	[15]	2026	Context-Aware Predictive Optimization of Non-Functional Requirement Conflicts in DevOps Using Machine Learning	Pemantauan; Operasi; optimasi runtime	Optimasi & RL / ML Klasik	Eksperimen Terkontrol
PS003	[16]	2025	Anomaly Detection Algorithms for Real-Time Log Data Analysis at Scale	Pemantauan; Operasi	AI Tanpa Pengawasan / Anomali	Empiris Industri
PS004	[17]	2019	AIOps for a Cloud Object Storage Service	Pemantauan; Operasi; Insiden/RCA	ML Klasik	Produksi
PS005	[18]	2025	AI-Augmented DevSecOps Pipelines for Secure and Scalable Service-Oriented Architectures in Cloud-Native Systems	Build; Pengujian; Deployment; Pemantauan; Operasi	Deep Learning	Eksperimen Terkontrol

PS ID	Sitasi	Tahun	Judul	Tahap DevOps	Kategori AI	Kekuatan Bukti
PS006	[19]	2023	Scalable and Accurate Test Case Prioritization in Continuous Integration Contexts	Build/CI; Pengujian	ML Klasik	Benchmark
PS007	[20]	2026	Predicting Intermittent Job Failure Categories for Diagnosis Using Few-Shot Fine-Tuned Language Models	Build/CI; Diagnosis Insiden	AI Generatif / LLM*	Empiris Industri
PS008	[21]	2024	Interaction Prediction and Anomaly Detection in a Microservices-based Telecommunication Platform	Pemantauan; Operasi; Insiden	AI Tanpa Pengawasan / Anomali	Empiris Industri
PS009	[22]	2024	Commit Artifact Preserving Build Prediction	Build / CI	NLP / Pembelajaran Representasi	Benchmark
PS010	[23]	2022	Scalability Testing Automation using Multivariate Characterization and Detection of Software Performance Antipatterns	Pengujian; CI/CD; pemantauan kinerja	ML Klasik	Empiris Industri
PS011	[24]	2024	An AIOps Approach to Data Cloud Based on Large Language Models	Pemantauan; Operasi; Insiden; Otomatisasi	AI Generatif / LLM	Konseptual / Terapan
PS012	[10]	2020	DeCaf: Diagnosing and Triaging Performance Issues in Large-Scale Cloud Services	Pemantauan; Operasi; Insiden/RCA	Machine Learning Klasik	Produksi
PS013	[25]	2023	On-Premise AIOps Infrastructure for a Software Editor SME: An Experience Report	Pemantauan; Operasi; Manajemen Insiden	Machine Learning Klasik	Produksi
PS014	[26]	2022	KubeKlone: A Digital Twin for Simulating Edge and Cloud Microservices	Operasi; Manajemen Sumber Daya	Machine Learning Klasik	Simulasi
PS015	[27]	2021	Automated User Experience Testing through Multi-Dimensional Performance Impact Analysis	Pengujian; Build/CI	Machine Learning Klasik	Eksperimen Terkontrol
PS016	[28]	2023	Security in DevSecOps: Applying Tools and Machine Learning to Verification and Monitoring Steps	Pengembangan /IaC; Pengujian; Deployment; Pemantauan	NLP / Pembelajaran Representasi	Empiris Industri
PS017	[29]	2020	Towards Intelligent Incident Management: Why We Need It and How We Make It	Pemantauan; Operasi; Manajemen Insiden	NLP / Pembelajaran Representasi	Empiris Industri
PS018	[30]	2022	Characterizing and Triaging Change Points	Pengujian; Pemantauan / Rekayasa Kinerja	Machine Learning Klasik	Benchmark / Eksperimen Terkontrol
PS019	[31]	2025	Predictive Resource Management in the Computing Continuum: Transfer Learning from Virtual Machines to Containers	Operasi; Manajemen Sumber Daya	Deep Learning	Benchmark

PS ID	Sitasi	Tahun	Judul	Tahap DevOps	Kategori AI	Kekuatan Bukti
PS020	[32]	2026	Leveraging Time Series Foundation Models to Detect Performance Anomalies in Software Systems	Pemantauan; Operasi	AI Generatif / LLM / Foundation Models	Benchmark
PS021	[33]	2024	An Architecture for Model-Based and Intelligent Automation in DevOps	Pengembangan ; Pengujian; Deployment; Pemantauan; Operasi	Machine Learning Klasik*	Empiris Industri
PS022	[34]	2025	Integrating Time Series Anomaly Detection Into DevOps Workflows	Pengujian; Pemantauan / Observabilitas	AI Tanpa Pengawasan / Anomali	Empiris Industri
PS023	[35]	2019	Monitorless: Predicting Performance Degradation in Cloud Applications with Machine Learning	Pengujian; Deployment; Pemantauan; Operasi	Machine Learning Klasik	Eksperimen Terkontrol
PS024	[36]	2022	Utilizing Persistence for Post Facto Suppression of Invalid Anomalies Using System Logs	Pemantauan; Operasi	AI Tanpa Pengawasan / Anomali	Eksperimen Terkontrol
PS025	[37]	2026	Enhancing DevOps Continuous Monitoring Phase: Hybrid Intrusion Detection and Ensemble Learning System (HIDELS)	Pengujian; Deployment; Pemantauan	Machine Learning Klasik	Eksperimen Terkontrol
PS026	[38]	2026	“Still in the Loop”: Coping with Technostress in DevOps Teams and the Impact of GenAI	Lintas-Aspek / Berpusat pada Manusia	AI Generatif / LLM	Empiris Industri
PS027	[39]	2024	Security Anomaly Detection in Enterprise GitHub	Pengembangan ; Pemantauan; DevSecOps	AI Tanpa Pengawasan / Anomali	Empiris Industri
PS028	[40]	2022	Towards a Consistent Interpretation of AIOps Models	Operasi; Tata Kelola Model AIOps	Machine Learning Klasik	Benchmark
PS029	[41]	2024	AIOps and Sustainability: Transforming Data Centers for a Greener Future	Pemantauan; Operasi	Machine Learning Klasik	Empiris Industri
PS030	[42]	2024	Machine Learning-based Test Case Prioritization using Hyperparameter Optimization	Build / CI; Pengujian	Optimasi & Reinforcement Learning**	Benchmark
PS031	[43]	2022	An Intelligent Framework for Timely, Accurate, and Comprehensive Cloud Incident Detection	Pemantauan; Operasi; Manajemen Insiden	Machine Learning Klasik	Produksi
PS032	[44]	2023	Proactive Auto-Scaling Approach of Production Applications Using an Ensemble Model	Pemantauan; Operasi; Manajemen Sumber Daya	Machine Learning Klasik	Empiris Industri
PS033	[45]	2024	On the Model Update Strategies for Supervised Learning in AIOps Solutions	Operasi; Tata Kelola / Pemeliharaan Model AIOps	Machine Learning Klasik	Benchmark

PS ID	Sitasi	Tahun	Judul	Tahap DevOps	Kategori AI	Kekuatan Bukti
PS034	[46]	2021	Continuous Test Suite Failure Prediction	Build / CI; Pengujian	Machine Learning Klasik	Benchmark
PS035	[47]	2022	Within-Project Defect Prediction of Infrastructure-as-Code Using Product and Process Metrics	Pengembangan / IaC; Pengujian / QA	Machine Learning Klasik	Benchmark
PS036	[48]	2026	Breaking the Observability Tax: Dynamic Resolution Anomaly Detection via Topology-Aware Active LLM Agents	Pemantauan; Operasi; Diagnosis Insiden	AI Agentik / Multi-Agen	Simulasi
PS037	[49]	2026	Data-Driven Test Case Prioritization (DD-TCP): A Machine Learning Framework for Intelligent Software Quality Assurance	Build / CI; Pengujian	Machine Learning Klasik	Benchmark
PS038	[50]	2023	Knowledge-based Intelligent System for IT Incident DevOps	Operasi; Manajemen Insiden	NLP / Pembelajaran Representasi	Empiris Industri
PS039	[51]	2020	Towards AIOps in Edge Computing Environments	Pemantauan; Operasi; Remediasi	Machine Learning Klasik	Eksperimen Terkontrol
PS040	[52]	2024	Advancing Software Security and Reliability in Cloud Platforms through AI-based Anomaly Detection	Build; Pengujian; Deployment; Pemantauan	Deep Learning	Eksperimen Terkontrol
PS041	[53]	2025	Cross-System Categorization of Abnormal Traces in Microservice-Based Systems via Meta-Learning	Pemantauan; Operasi; Insiden/RCA	Deep Learning	Benchmark
PS042	[12]	2026	LLM-based AIOps via Log Prioritization in Air-Gapped Systems	Pemantauan; Operasi; Diagnosis Insiden	AI Generatif / LLM	Empiris Industri
PS043	[54]	2021	KPI Anomaly Detection Method for Data Center AIOps Based on GRU-GAN	Pemantauan; Operasi	Deep Learning	Benchmark
PS044	[55]	2023	A Case Study of AIOps in Large Enterprises Using Predictive Analytics for IT Operations	Pemantauan; Operasi	Machine Learning Klasik	Empiris Industri
PS045	[7]	2026	ARM: Autonomous Remediation & Management with LLM Agents for Intent-Driven Control	Pemantauan; Operasi; Insiden/RCA; Remediasi	AI Agentik / Multi-Agen	Eksperimen Terkontrol
PS046	[56]	2026	LLM Agents for AIOps in Kubernetes: An Industrial Experience Report with Red Hat OpenShift	Pemantauan; Operasi; Perencanaan Kapasitas; Remediasi	AI Agentik / Multi-Agen	Empiris Industri
PS047	[57]	2024	Commit Artifact Preserving Build Prediction	Build / CI	NLP / Pembelajaran Representasi†	Benchmark

PS ID	Sitasi	Tahun	Judul	Tahap DevOps	Kategori AI	Kekuatan Bukti
PS048	[58]	2024	LogExpert: Log-based Recommended Resolutions Generation using Large Language Model	Pemantauan; Operasi; Insiden/Remedi asi	AI Generatif / LLM	Benchmark
PS049	[13]	2026	Graph-Augmented Multi-Agent Robust Root Cause Analysis in AIOps	Pemantauan; Operasi; Insiden/RCA	AI Agentik / Multi-Agen	Benchmark
PS050	[59]	2026	DualLane: Fast and Reliable LLM Agents for Interactive AIOps via Dual-Path Planning	Operasi; Insiden/Dukun gan; Operasi Sumber Daya	AI Agentik / Multi-Agen	Produksi
PS051	[60]	2020	An Experimental Evaluation of Imbalanced Learning and Time-Series Validation in the Context of CI/CD Prediction	Build / CI; Deployment / CD	Machine Learning Klasik	Benchmark
PS052	[61]	2025	Fault Prediction in Large-Scale Cluster Environments Based on Improved TCN and DenseNet	Pemantauan; Operasi	Deep Learning	Eksperimen Terkontrol
PS053	[62]	2024	On the Effectiveness of Feature Selection Techniques in the Context of ML-Based Regression Test Prioritization	Build / CI; Pengujian	Machine Learning Klasik	Benchmark
PS054	[63]	2020	An Anomaly Detection Algorithm for Microservice Architecture Based on Robust Principal Component Analysis	Pemantauan; Operasi; Insiden/RCA	AI Tanpa Pengawasan / Anomali	Benchmark
PS055	[64]	2020	Env2Vec: Accelerating VNF Testing with Deep Learning	Build; Pengujian; Pra- deployment	Deep Learning	Empiris Industri
PS056	[8]	2019	Predictive Test Selection	Build / CI; Pengujian	Machine Learning Klasik	Produksi
PS057	[9]	2020	Predicting Node Failures in an Ultra-Large-Scale Cloud Computing Platform: An AIOps Solution	Pemantauan; Operasi	Machine Learning Klasik	Produksi
PS058	[65]	2021	An Empirical Study of the Impact of Data Splitting Decisions on the Performance of AIOps Solutions	Operasi; Tata Kelola / Pemeliharaan Model AIOps	Machine Learning Klasik	Benchmark
PS059	[66]	2025	PA-Rank: A GAN and Reinforcement Learning Powered Framework for Multi-Metric Anomaly Detection and Causal Diagnosis	Pemantauan; Operasi; Insiden/RCA	Optimasi & Reinforcement Learning	Benchmark
PS060	[11]	2024	Automated Root Causing of Cloud Incidents using In-Context Learning with GPT-4	Operasi; Insiden/RCA	AI Generatif / LLM	Empiris Industri

5. Diskusi

5.1 Evolusi DevOps Berbasis AI

Hasil menunjukkan fase-fase yang saling tumpang tindih, bukan penggantian sederhana terhadap pendekatan yang lebih lama. Penelitian awal terutama berpusat pada model, menggunakan prediksi, klasifikasi, deteksi anomali, dan analitik diagnostik. Ketika metode ini tertanam dalam workflow operasional, unit otomatisasi meluas dari model terisolasi menuju pipeline yang mengumpulkan bukti, memicu analisis, dan mendukung keputusan operasional.

LLM memperluas arsitektur ini dengan memungkinkan penalaran atas bukti operasional yang heterogen dan tidak terstruktur. Hal ini mendukung transisi dari Model → Pipeline → Sistem Penalaran. Sistem agentik yang mulai berkembang menambahkan perencanaan, alat, verifikasi, dan eksekusi terkoordinasi, sehingga memperluas lintasan menuju Sistem Agentik. Secara paralel, kedalaman fungsional otomatisasi dapat ditafsirkan sebagai Bantu → Prediksi → Diagnosis → Rekomendasi → Tindakan.

Pendekatan yang lebih baru tidak secara otomatis menggantikan metode machine learning yang telah mapan. Teknik klasik dan berorientasi anomali tetap berguna ketika kinerja, efisiensi, interpretabilitas, dan kebutuhan operasionalnya telah dipahami dengan baik. Sistem generatif dan agentik memperluas rentang tugas yang dapat ditangani, tetapi juga memperkenalkan kekhawatiran baru terkait keandalan, biaya, dan keselamatan.

Secara keseluruhan, korpus mendukung evolusi yang lebih luas dari AI Prediktif → AIOps Diagnostik → AI Generatif → AI Agentik. Namun, kapabilitas teknis berkembang lebih cepat daripada bukti berkelanjutan mengenai manfaat produksi, khususnya untuk pendekatan berbasis LLM dan agentik. Oleh karena itu, arah jangka panjang dapat dinyatakan sebagai Prediktif → Diagnostik → Generatif → Agentik → DevOps Otonom yang Tepercaya, dengan tahap akhir dipahami sebagai arah penelitian, bukan tingkat kematangan yang telah mapan.

5.2 Konsentrasi Operasional dan Kematangan Otomatisasi

Distribusi RQ2 menunjukkan konsentrasi kuat ke sisi operasional: pemantauan dan observabilitas, operasi, serta insiden/RCA/remediasi mendominasi korpus. Tahapan ini menghasilkan telemetri berkelanjutan dan masalah operasional berulang yang secara alami sesuai untuk analisis berbasis data, pengurangan ketidakpastian, dan dukungan keputusan repetitif.

Jumlah yang lebih rendah pada pengembangan, build, dan deployment tidak berarti AI tidak relevan bagi tahapan siklus hidup yang lebih awal. Sebaliknya, hal itu mencerminkan ruang lingkup dan framing literatur yang ditinjau, yang menekankan data operasional dan manajemen kegagalan.

Pandangan dua dimensi tentang kematangan menggabungkan keluasan keterlibatan operasional—Pemantauan → Operasi → Diagnosis → Remediasi—dengan kedalaman otomatisasi—Bantu → Prediksi → Diagnosis → Rekomendasi → Tindakan. Ketika sistem bergerak menuju Tindakan, konsekuensi kesalahan menjadi lebih signifikan. Karena itu, verifikasi bukti, izin, persetujuan manusia untuk tindakan berdampak tinggi, eksekusi aman, auditabilitas, rollback, dan eskalasi menjadi semakin penting.

Kematangan otomatisasi dengan demikian harus dinilai tidak hanya berdasarkan kecanggihan model, tetapi juga berdasarkan tanggung jawab operasional dan kekuatan bukti.

5.3 Kematangan Bukti dan Kesenjangan Benchmark-ke-Produksi

Enam kategori kekuatan bukti memberikan lensa penting untuk menafsirkan RQ4. Bukti produksi memberikan indikasi langsung terkuat bahwa suatu pendekatan dapat beroperasi di bawah kendala organisasi dan sistem yang nyata. Studi empiris industri memberikan bukti realistis tetapi masih dapat terbatas dalam durasi, ruang lingkup, atau integrasi operasional. Eksperimen terkontrol dan benchmark penting untuk perbandingan teknis, sedangkan simulasi dan pekerjaan konseptual terutama menunjukkan kelayakan.

Contoh produksi seperti [8], [9], dan [10] menunjukkan deployment operasional langsung. [11] dan [12] memberikan bukti empiris industri, sedangkan [13] menunjukkan kapabilitas teknis pada tingkat benchmark. Jenis bukti ini tidak boleh diperlakukan sebagai hal yang dapat dipertukarkan.

Lingkungan produksi memperkenalkan evolusi sistem, concept drift, telemetri yang bising, integrasi alat, kendala keamanan, variasi beban kerja, latensi, biaya, dan konsekuensi tindakan yang salah. Karena itu, akurasi benchmark atau skor F1 yang tinggi tidak boleh ditafsirkan sebagai bukti penurunan MTTR atau peningkatan ketersediaan.

Evaluasi yang lebih matang harus menghubungkan kinerja algoritmik dengan hasil operasional seperti waktu penyelesaian insiden, tingkat tindakan salah, waktu deteksi atau diagnosis, MTTR, ketersediaan, upaya rekayasa, intervensi manusia, biaya, latensi, dan keselamatan. Kematangan bukti karena itu memerlukan baik kinerja teknis maupun efektivitas operasional yang telah dibuktikan.

5.4 Kesenjangan Penelitian

G1 Validasi Skala Produksi. Diperlukan lebih banyak studi yang mengevaluasi AI-for-DevOps dalam kondisi produksi yang berkelanjutan dan realistis serta melaporkan hasil operasional, bukan hanya metrik model offline.

G2 Generalisasi Lintas Sistem. Model sering bergantung pada telemetri, arsitektur, atau pola insiden yang spesifik terhadap sistem. Penelitian perlu mengevaluasi transfer lintas sistem, organisasi, domain, dan konfigurasi infrastruktur.

G3 Concept Drift dan Pemeliharaan Jangka Panjang. Lingkungan DevOps terus berkembang. Penelitian masa depan perlu menangani deteksi drift, adaptasi berkelanjutan, strategi pelatihan ulang, dan pemantauan terhadap sistem AI itu sendiri.

G4 Explainability, Kepercayaan, dan Keandalan. Keputusan operasional memerlukan bukti yang ter-grounding, estimasi ketidakpastian, keterlacakan, serta mekanisme untuk mengurangi halusinasi dan rekomendasi yang tidak didukung.

G5 Keamanan Remediasi Otonom. Sistem yang mampu bertindak memerlukan otonomi terbatas, verifikasi, penegakan kebijakan, otorisasi, rollback, auditabilitas, dan eskalasi. Pertanyaan utamanya adalah dalam kondisi apa sebuah sistem AI seharusnya diizinkan untuk bertindak.

G6 Biaya dan Latensi LLM/Agen. Penalaran multi-langkah, pemanggilan alat, konteks panjang, dan interaksi multi-agen dapat menimbulkan overhead komputasi dan waktu respons yang signifikan. Kapabilitas harus diseimbangkan dengan efisiensi operasional.

G7 Kolaborasi dan Adopsi Manusia-AI. Penelitian perlu mengkaji supervisi, persetujuan, kepercayaan, akuntabilitas, keterampilan, adopsi organisasi, serta bagaimana AI mengubah, bukan sekadar menggantikan, pekerjaan operasional.

G8 Evaluasi Operasional Terpadu ML dan DevOps. Kerangka evaluasi perlu menghubungkan metrik tingkat model dengan hasil tingkat DevOps, dengan mengukur baik kualitas prediksi atau penalaran maupun efek operasional hilir.

Sebagai prioritas tingkat sintesis dan bukan prevalensi statistik, G1, G5, dan G8 muncul sebagai kesenjangan dengan prioritas tertinggi; G2, G3, dan G4 juga berprioritas tinggi; sedangkan G6 dan G7 merupakan area prioritas tinggi yang sedang berkembang.

5.5 Agenda Penelitian Masa Depan

FR1 AI-for-DevOps yang Tervalidasi di Produksi. Studi produksi longitudinal perlu mengevaluasi keandalan, hasil operasional, beban pemeliharaan, biaya, dan keselamatan dari waktu ke waktu.

FR2 AIOps yang Adaptif dan Dapat Digeneralisasi. Sistem masa depan perlu memasukkan kesadaran terhadap drift, continual learning, transfer lintas sistem, adaptasi domain, dan pemantauan terhadap kinerjanya sendiri.

FR3 LLM-AIOps yang Tepercaya dan Dapat Dijelaskan. Penelitian perlu memprioritaskan grounding, mitigasi halusinasi, ketidakpastian, penjelasan, keterlacakan, konsistensi, verifikasi, dan perlindungan informasi operasional sensitif.

FR4 DevOps Agentik yang Aman dan Efisien Biaya. Sistem agentik perlu menggunakan akses alat yang dibatasi, izin eksplisit, verifikasi, batasan kebijakan, sandboxing, rollback, log audit, eskalasi, serta kontrol biaya/latensi. Tujuannya adalah otonomi yang tepat di bawah batasan keselamatan eksplisit, bukan otonomi maksimum.

FR5 DevOps Otonom yang Berpusat pada Manusia. Sistem masa depan perlu mendukung pola bertahap seperti AI merekomendasikan → Manusia menyetujui; AI bertindak dalam kebijakan terbatas → Manusia mengawasi; dan AI bertindak secara otonom pada tugas berisiko rendah → Manusia menangani eskalasi. Kepercayaan, desain antarmuka, beban kerja, akuntabilitas, adopsi, dan keterampilan tetap menjadi aspek utama.

5.6 Menuju DevOps Otonom yang Tepercaya

Sistem DevOps otonom yang tepercaya harus dievaluasi pada berbagai dimensi: kapabilitas teknis, keandalan, kemampuan generalisasi, explainability dan grounding bukti, keselamatan, keamanan dan privasi, kelayakan ekonomi, serta tata kelola manusia.

Progresi otonomi yang praktis adalah Dipimpin Manusia → Dibantu AI → Direkomendasikan AI → Otomatisasi yang Diawasi Manusia → Operasi Otonom Terbatas. Dengan demikian, kematangan tidak dapat direduksi hanya menjadi kecanggihan model.

Lintasan jangka panjang yang ditunjukkan oleh tinjauan ini adalah Prediktif → Diagnostik → Generatif → Agentik → DevOps Otonom yang Tepercaya. Pertanyaan penelitian utama dengan demikian berubah dari “Dapatkah AI mengotomatisasi tugas DevOps ini?” menjadi “Di bawah bukti, batasan, dan tata kelola seperti apa AI dapat melakukan tugas ini secara aman dan andal di lingkungan produksi?” Tantangan utamanya adalah menutup kesenjangan antara kemungkinan teknis dan adopsi operasional yang tepercaya.

6. Ancaman terhadap Validitas

6.1 Validitas Konstruk

Validitas konstruk berkaitan dengan apakah definisi operasional dan klasifikasi yang digunakan dalam tinjauan ini secara memadai merepresentasikan AI untuk otomatisasi DevOps. Tinjauan ini secara sengaja membedakan AI-for-DevOps dari studi yang secara eksklusif berfokus pada MLOps atau DevOps-for-AI. Namun, area-area ini dapat tumpang tindih dalam praktik, sehingga beberapa studi batas sensitif terhadap interpretasi peninjau.

Klasifikasi juga memperkenalkan potensi subjektivitas. Untuk RQ2, studi dipetakan ke tahapan dan aktivitas DevOps menggunakan pendekatan multi-label karena satu studi dapat membahas beberapa tahapan, khususnya pemantauan, operasi, manajemen insiden, analisis akar penyebab, dan remediasi. Akibatnya, persentase RQ2 tidak saling eksklusif dan tidak diharapkan berjumlah 100%.

Untuk RQ3, pendekatan AI diklasifikasikan menjadi Machine Learning Klasik, Deep Learning, AI Tanpa Pengawasan/Anomali, Optimasi dan Reinforcement Learning, NLP/Pembelajaran Representasi, AI Generatif/LLM, dan AI Agentik/Multi-Agen. AIOps diperlakukan sebagai paradigma aplikasi, bukan kategori algoritmik. Kategori primer yang saling eksklusif digunakan untuk pelaporan kuantitatif, yang meningkatkan keterinterpretasian tetapi dapat menyederhanakan studi yang menggabungkan beberapa teknik AI.

Risiko-risiko ini dimitigasi melalui batas ruang lingkup yang eksplisit, pertanyaan penelitian yang telah ditentukan, aturan klasifikasi yang konsisten, dan skema ekstraksi terstruktur. Meskipun demikian, DevOps Stage, AI Category, RQ Mapping, dan Evidence Strength tetap merupakan klasifikasi analitis tingkat tinjauan, bukan selalu label yang didefinisikan oleh penulis studi.

6.2 Validitas Internal

Ancaman utama terhadap validitas internal adalah bias pengambilan teks lengkap. Pencarian mengidentifikasi 1.132 rekaman. Setelah dua rekaman dihapus sebelum penyaringan dan 317 kemunculan duplikat dieliminasi, 813 rekaman unik menjalani penyaringan judul dan abstrak. Dari jumlah tersebut, 431 dikeluarkan dan 382 laporan dicari untuk diambil.

Pengambilan diupayakan untuk seluruh 382 laporan, tetapi hanya 73 teks lengkap yang diperoleh, sedangkan 309 laporan tidak berhasil diambil. Penilaian kelayakan karena itu dibatasi pada 73 laporan yang tersedia. Hal ini merupakan keterbatasan substansial karena studi yang berpotensi relevan mungkin terdapat di antara laporan yang tidak tersedia. Oleh karena itu, 60 studi yang disertakan tidak boleh ditafsirkan sebagai mewakili seluruh studi yang berpotensi memenuhi syarat di antara 382 laporan yang dicari untuk diambil.

Dari 73 laporan yang diperoleh, 13 dikeluarkan selama penilaian teks lengkap, sehingga menghasilkan 60 studi yang disertakan. Seluruh 60 studi melewati ambang penilaian kualitas yang telah ditentukan dan menjalani ekstraksi data lengkap menggunakan skema ekstraksi 26-field. Namun, QA PASS menunjukkan pemenuhan ambang kualitas minimum dan tidak berarti kekuatan bukti yang setara. Korpus yang disertakan mencakup bukti Production, Industrial Empirical, Controlled Experimental, Benchmark, Simulation, dan Conceptual.

Pertimbangan peninjau selama penyaringan, ekstraksi, dan sintesis tematik juga memperkenalkan potensi bias klasifikasi. Penggunaan kriteria kelayakan eksplisit, field ekstraksi terstruktur, pengodean konsisten, dan perhitungan PRISMA yang transparan dimaksudkan untuk mengurangi, tetapi tidak dapat sepenuhnya menghilangkan, ancaman ini.

6.3 Validitas Eksternal

Validitas eksternal dibatasi oleh cakupan database dan karakteristik bukti yang disertakan. Pencarian mencakup ScienceDirect, IEEE Xplore, dan ACM Digital Library untuk periode 2016–2026. Meskipun sumber-sumber ini memberikan cakupan substansial terhadap penelitian rekayasa perangkat lunak dan komputasi, tinjauan ini tidak mengklaim cakupan yang menyeluruh atas seluruh literatur AI-for-DevOps.

Studi relevan yang hanya terindeks pada database lain, platform penerbit, repositori institusional, grey literature, atau laporan teknis industri karena itu mungkin tidak tercakup. Keterbatasan ini khususnya relevan bagi area yang berkembang cepat seperti DevOps berbasis LLM dan sistem agentik, ketika perkembangan industri dapat mendahului publikasi akademik formal.

Generalisasi juga dibatasi oleh perbedaan dataset, sistem perangkat lunak, infrastruktur, lingkungan organisasi, dan desain evaluasi. Bukti yang diperoleh dari benchmark, simulasi, eksperimen terkontrol, atau studi konseptual tidak dapat secara otomatis digeneralisasi ke lingkungan produksi. Sintesis karena itu membedakan kekuatan bukti dan menghindari perlakuan kinerja eksperimental sebagai setara dengan dampak industri yang telah dibuktikan.

6.4 Validitas Kesimpulan

Validitas kesimpulan berkaitan dengan apakah kesimpulan proporsional terhadap bukti yang tersedia. Tinjauan ini menggunakan analisis kuantitatif deskriptif dan sintesis tematik kualitatif, bukan meta-analisis statistik, karena studi yang disertakan berbeda secara substansial dalam desain penelitian, dataset, metrik, konteks, dan kekuatan bukti.

Untuk RQ4, tujuh tema manfaat diidentifikasi, tetapi frekuensi seluruh korpus yang dapat direproduksi pada seluruh 60 studi tidak tersedia. Oleh karena itu, tinjauan tidak menyimpulkan peringkat prevalensi di antara tema manfaat. Visualisasi berdasarkan jangkai bukti representatif menunjukkan cakupan di antara jangkai tersebut, bukan frekuensi pada seluruh korpus.

Demikian pula, empat belas tema tantangan dan delapan kesenjangan penelitian yang disintesis untuk RQ5 tidak memiliki frekuensi seluruh korpus yang dapat direproduksi. Prioritasnya karena itu harus ditafsirkan sebagai sintesis yang diinformasikan oleh bukti, bukan prevalensi statistik.

Tinjauan ini selanjutnya menerapkan aturan interpretasi konservatif. Kinerja benchmark tidak dianggap setara dengan dampak produksi; peningkatan metrik prediktif tidak selalu menyiratkan peningkatan ukuran operasional seperti MTTR; AI tidak diasumsikan menggantikan engineer DevOps; dan pendekatan AIOps agentik yang sedang berkembang tidak dianggap siap produksi secara luas tanpa bukti produksi yang memadai.

Secara keseluruhan, temuan harus ditafsirkan sebagai sintesis sistematis atas literatur yang dapat diakses dan memenuhi syarat sebagaimana ditangkap oleh protokol tinjauan, bukan sebagai gambaran yang menyeluruh atau representatif secara statistik atas seluruh penelitian AI-for-DevOps. Risiko validitas dimitigasi melalui definisi ruang lingkup yang eksplisit, perhitungan PRISMA yang transparan, penyaringan sistematis, penilaian kualitas, ekstraksi data terstruktur, sintesis yang mempertimbangkan kekuatan bukti, dan pelaporan klaim kuantitatif secara konservatif.

7. Kesimpulan

Tinjauan literatur sistematis ini menyelidiki perkembangan, aplikasi, metode, manfaat, tantangan, dan arah masa depan Kecerdasan Artifisial untuk otomatisasi DevOps antara 2016 dan 2026. Tinjauan secara khusus berfokus pada AI-for-DevOps, yaitu teknik AI digunakan untuk meningkatkan atau mengotomatisasi aktivitas DevOps, sedangkan studi yang secara eksklusif membahas MLOps atau DevOps-for-AI berada di luar ruang lingkup tinjauan.

Tinjauan mengidentifikasi 1.132 rekaman database dari ScienceDirect, IEEE Xplore, dan ACM Digital Library. Setelah penghapusan, deduplikasi, penyaringan judul dan abstrak, pengambilan teks lengkap, dan penilaian kelayakan, 60 studi primer disertakan dalam korpus final. Seluruh studi yang disertakan melewati ambang penilaian kualitas yang telah ditentukan dan dianalisis menggunakan skema ekstraksi data terstruktur 26-field.

Terkait RQ1, hasil menunjukkan bahwa aktivitas penelitian semakin terkonsentrasi pada tahun-tahun akhir periode tinjauan. Lebih dari separuh studi yang disertakan dipublikasikan selama 2024–2026. Di seluruh korpus, perkembangan teknologi AI-for-DevOps mencerminkan progresi dari pendekatan yang terutama prediktif dan

diagnostik menuju AI Generatif, sistem berbasis LLM, dan pendekatan agentik atau multi-agen yang mulai berkembang.

Terkait RQ2, aplikasi AI terutama terkonsentrasi pada pemantauan dan observabilitas, operasi, serta aktivitas insiden/akar penyebab/remediasi. Hal ini menunjukkan orientasi operasional yang kuat dalam literatur yang ditinjau, sementara relatif lebih sedikit studi yang membahas aktivitas pengembangan, build, dan deployment.

Terkait RQ3, Machine Learning Klasik tetap menjadi kategori AI primer yang dominan, sementara korpus juga mencakup Deep Learning, AI Tanpa Pengawasan/Anomali, Optimasi dan Reinforcement Learning, NLP/Pembelajaran Representasi, AI Generatif/LLM, dan AI Agentik/Multi-Agen. AIOps diperlakukan sebagai paradigma aplikasi, bukan kategori algoritmik. Koeksistensi pendekatan-pendekatan ini menunjukkan diversifikasi metodologis, bukan penggantian metode yang telah mapan oleh teknologi yang lebih baru.

Terkait RQ4, sintesis kualitatif mengidentifikasi manfaat berulang terkait kecepatan dan efisiensi, akurasi dan kualitas deteksi, keandalan dan ketersediaan, optimasi biaya dan sumber daya, otomatisasi dan pengurangan toil, peningkatan keamanan, serta dukungan keputusan manusia dan produktivitas. Tema-tema ini tidak boleh ditafsirkan sebagai peringkat prevalensi seluruh korpus karena frekuensi yang dapat direproduksi untuk seluruh 60 studi tidak tersedia. Selain itu, kekuatan bukti yang mendukung manfaat yang dilaporkan sangat bervariasi pada lingkungan Production, Industrial Empirical, Controlled Experimental, Benchmark, Simulation, dan Conceptual.

Pembedaan ini mengarah pada salah satu kesimpulan utama tinjauan: kapabilitas teknis berkembang lebih cepat daripada manfaat produksi yang telah dibuktikan, khususnya untuk pendekatan berbasis LLM dan agentik. Kinerja benchmark atau eksperimental yang kuat memberikan bukti berharga mengenai kelayakan teknis, tetapi tidak boleh diperlakukan setara dengan dampak operasional yang telah dibuktikan.

Terkait RQ5, tinjauan mengidentifikasi empat belas tema tantangan berulang yang mencakup kualitas data, ketidakseimbangan kelas, evaluasi tidak realistis, concept drift, kemampuan generalisasi, kesenjangan benchmark-ke-produksi, explainability, keandalan LLM, biaya dan latensi, kompleksitas integrasi, keamanan remediasi otonom, pengawasan manusia, keamanan dan privasi, serta inkonsistensi evaluasi.

Tantangan tersebut disintesis menjadi delapan kesenjangan penelitian: validasi skala produksi, generalisasi lintas sistem, concept drift dan pemeliharaan jangka panjang, explainability/kepercayaan/keandalan, keamanan remediasi otonom, biaya dan latensi LLM/agen, kolaborasi dan adopsi manusia-AI, serta evaluasi operasional terpadu ML-plus-DevOps.

Delapan kesenjangan tersebut selanjutnya dikonsolidasikan menjadi lima arah penelitian masa depan: AI-for-DevOps yang Tervalidasi di Produksi, AIOps yang Adaptif dan Dapat Digeneralisasi, LLM-AIOps yang Tepercaya dan Dapat Dijelaskan, DevOps Agentik yang Aman dan Efisien Biaya, serta DevOps Otonom yang Berpusat pada Manusia.

Secara keseluruhan, literatur yang ditinjau menunjukkan lintasan teknologi yang lebih luas: Prediktif → Diagnostik → Generatif → Agentik → DevOps Otonom yang Tepercaya.

Tahap akhir tidak boleh ditafsirkan sebagai tingkat kematangan industri yang telah mapan. Sebaliknya, tahap tersebut merepresentasikan arah penelitian di mana peningkatan kapabilitas AI harus disertai bukti yang lebih kuat mengenai keandalan, kemampuan generalisasi, keselamatan, kelayakan ekonomi, explainability, tata kelola, dan pengawasan manusia yang sesuai.

Tantangan utama penelitian DevOps berbasis AI di masa depan karena itu bergeser dari menunjukkan apakah AI dapat melakukan suatu tugas operasional menuju penentuan di bawah bukti, batasan, dan kondisi tata kelola seperti apa AI dapat melakukan tugas tersebut secara aman dan andal di lingkungan produksi.

Kemajuan masa depan tidak hanya bergantung pada teknik AI yang semakin mampu, tetapi juga pada penutupan kesenjangan antara kemungkinan teknis dan adopsi operasional yang tepercaya.

Referensi

[1] R. Jabbari, N. Bin Ali, K. Petersen, and B. Tanveer, "What is DevOps?: A systematic mapping study on definitions and practices," in Proc. XP 2016 Scientific Workshops, Edinburgh, U.K., 2016, Art. no. 12, doi: 10.1145/2962695.2962707.

- [2] P. Notaro, J. Cardoso, and M. Gerndt, “A survey of AIOps methods for failure management,” *ACM Trans. Intell. Syst. Technol.*, vol. 12, no. 6, Art. no. 81, 2021, doi: 10.1145/3483424.
- [3] T. Ahmed, S. Ghosh, C. Bansal, T. Zimmermann, X. Zhang, and S. Rajmohan, “Recommending root-cause and mitigation steps for cloud incidents using large language models,” in *Proc. 45th IEEE/ACM Int. Conf. Software Engineering (ICSE)*, Melbourne, Australia, 2023, doi: 10.1109/ICSE48619.2023.00149.
- [4] X. Hou, Y. Zhao, Y. Liu, Z. Yang, K. Wang, L. Li, X. Luo, D. Lo, J. Grundy, and H. Wang, “Large language models for software engineering: A systematic literature review,” *ACM Trans. Softw. Eng. Methodol.*, vol. 33, no. 8, Art. no. 220, pp. 1–79, 2024, doi: 10.1145/3695988.
- [5] M. Bilal, J. Crowcroft, R. Wang, X. Xu, and S. Dustdar, “Large language models for agentic NetOps and AIOps: Architectures, evaluation, and safety,” *arXiv preprint arXiv:2605.12729*, 2026.
- [6] B. M. A. Matsui and D. H. Goya, “MLOps: Five steps to guide its effective implementation,” in *Proc. 2022 IEEE/ACM 1st Int. Conf. AI Engineering—Software Engineering for AI (CAIN)*, Pittsburgh, PA, USA, 2022, pp. 33–34, doi: 10.1145/3522664.3528611.
- [7] Vasilis Avgerinos; Kostas Ramantas; Luis Alonso; Christos Verikoukis, “ARM: Autonomous Remediation and Management With LLM Agents for Intent-Driven Control,” *IEEE Internet of Things Journal*, 2026, doi: 10.1109/jiot.2025.3648858.
- [8] Mateusz Machalica; Alex Samykin; Meredith Porth; Satish Chandra, “Predictive Test Selection,” in *2019 IEEE/ACM 41st International Conference on Software Engineering: Software Engineering in Practice (ICSE-SEIP)*, 2019, doi: 10.1109/icse-seip.2019.00018.
- [9] Yangguang Li; Zhen Ming (Jack) Jiang; Heng Li; Ahmed E. Hassan; Cheng He; Ruirui Huang; Zhengda Zeng; Mian Wang; Pinan Chen, “Predicting Node Failures in an Ultra-Large-Scale Cloud Computing Platform: An AIOps Solution,” *ACM Transactions on Software Engineering and Methodology (TOSEM)*, 2020, doi: 10.1145/3385187.
- [10] Chetan Bansal; Sundararajan Renganathan; Ashima Asudani; Olivier Midy; Mathru Janakiraman, “DeCaf: diagnosing and triaging performance issues in large-scale cloud services,” in *conference/workshop venue not preserved in canonical screening metadata*, 2020, doi: 10.1145/3377813.3381353.
- [11] Xuchao Zhang; Supriyo Ghosh; Chetan Bansal; Rujia Wang; Minghua Ma; Yu Kang; Saravan Rajmohan, “Automated Root Causing of Cloud Incidents using In-Context Learning with GPT-4,” in *conference/workshop venue not preserved in canonical screening metadata*, 2024, doi: 10.1145/3663529.3663846.
- [12] SangHee Song; Hwajung Kim, “LLM-based AIOps via Log Prioritization in Air-Gapped Systems,” in *conference/workshop venue not preserved in canonical screening metadata*, 2026, doi: 10.1145/3805621.3807626.
- [13] Haodong Zou; Yichen Zhao; Xin Chen; Ling Wang; Jinghang Yu; Long Yuan, “Graph-Augmented Multi-Agent Robust Root Cause Analysis in AIOps,” *Computers, Materials and Continua*, 2026, doi: 10.32604/cmc.2026.077908.
- [14] Liang Bai; Guzainuer Aizaizi; Xinying Guo; Xudong Pan; Yedeli Bolati, “Research on Big Data Analysis and Anomaly Detection Algorithms in Intelligent Operations and Maintenance,” in *conference/workshop venue not preserved in canonical screening metadata*, 2025, doi: 10.1145/3729605.3729705.
- [15] Anirban Bhar et al., “Context-Aware Predictive Optimization of Non-Functional Requirement Conflicts in DevOps Using Machine Learning,” *IEEE Access*, 2026, doi: 10.1109/access.2026.3727789.
- [16] András Horváth et al., “Anomaly Detection Algorithms for Real-Time Log Data Analysis at Scale,” *IEEE Access*, 2025, doi: 10.1109/access.2025.3594469.
- [17] Anna Levin; Shelly Garion; Elliot K. Kolodner; Dean H. Lorenz; Katherine Barabash; Mike Kugler; Niall McShane, “AIOps for a Cloud Object Storage Service,” in *2019 IEEE International Congress on Big Data (BigDataCongress)*, 2019, doi: 10.1109/bigdatacongress.2019.00036.
- [18] Akshay Mittal, “AI-Augmented DevSecOps Pipelines for Secure and Scalable Service-Oriented Architectures in Cloud-Native Systems,” in *2025 IEEE International Conference on Service-Oriented System Engineering (SOSE)*, 2025, doi: 10.1109/sose67019.2025.00014.
- [19] Ahmadreza Saboor Yaraghi; Mojtaba Bagherzadeh; Nafiseh Kahani; Lionel Briand, “Scalable and Accurate Test Case Prioritization in Continuous Integration Contexts,” *IEEE Transactions on Software Engineering*, 2023, doi: 10.1109/tse.2022.3184842.
- [20] Henri Aïdasso; Francis Bordeleau; Ali Tizghadam, “Predicting Intermittent Job Failure Categories for Diagnosis Using Few-Shot Fine-Tuned Language Models,” in *conference/workshop venue not preserved in canonical screening metadata*, 2026, doi: 10.1145/3803437.3805224.
- [21] Kemal Aktaş; H. Hakan Kilinc, “Interaction Prediction and Anomaly Detection in a Microservices-based Telecommunication Platform,” in *conference/workshop venue not preserved in canonical screening metadata*, 2024, doi: 10.1145/3666015.3666017.

- [22] Guoqing Wang; Zeyu Sun; Yizhou Chen; Yifan Zhao; Qingyuan Liang; Dan Hao, "Predicting build outcomes in continuous integration using textual analysis of source code commits," in conference/workshop venue not preserved in canonical screening metadata, 2022, doi: 10.1145/3558489.3559070.
- [23] Alberto Avritzer et al., "Scalability testing automation using multivariate characterization and detection of software performance antipatterns," *Journal of Systems and Software*, 2022, doi: 10.1016/j.jss.2022.111446.
- [24] Honghua Chen et al., "An AIOps Approach to Data Cloud Based on Large Language Models," in conference/workshop venue not preserved in canonical screening metadata, 2024, doi: 10.1145/3690407.3690515.
- [25] Anes Bendimerad; Youcef Remil; Romain Mathonat; Mehdi Kaytoue, "On-Premise AIOps Infrastructure for a Software Editor SME: An Experience Report," in conference/workshop venue not preserved in canonical screening metadata, 2023, doi: 10.1145/3611643.3613876.
- [26] Ayush Bhardwaj; Theophilus A. Benson, "KubeKlone: A Digital Twin for Simulating Edge and Cloud Microservices," in conference/workshop venue not preserved in canonical screening metadata, 2023, doi: 10.1145/3542637.3542642.
- [27] Chidera Biringa; Gokhan Kul, "Automated User Experience Testing through Multi-Dimensional Performance Impact Analysis," in 2021 IEEE/ACM International Conference on Automation of Software Test (AST), 2021, doi: 10.1109/ast52587.2021.00024.
- [28] Matija Cankar; Nenad Petrović; Joao Pita Costa; Aleš Černivec; Jan Antić; Tomaž Martinčič; Dejan Štepec, "Security in DevSecOps: Applying Tools and Machine Learning to Verification and Monitoring Steps," in conference/workshop venue not preserved in canonical screening metadata, 2023, doi: 10.1145/3578245.3584943.
- [29] Chen et al., "Towards intelligent incident management: why we need it and how we make it," in conference/workshop venue not preserved in canonical screening metadata, 2020, doi: 10.1145/3368089.3417055.
- [30] Chen et al., "Characterizing and Triaging Change Points," in conference/workshop venue not preserved in canonical screening metadata, 2022, doi: 10.1145/3491204.3527487.
- [31] De Novi et al., "Predictive Resource Management in the Computing Continuum: Transfer Learning from Virtual Machines to Containers using Transformers," in conference/workshop venue not preserved in canonical screening metadata, 2026, doi: 10.1145/3773274.3774856.
- [32] Di Menna et al., "Leveraging Time Series Foundation Models to Detect Performance Anomalies in Software Systems," in conference/workshop venue not preserved in canonical screening metadata, 2026, doi: 10.1145/3777911.3800632.
- [33] Romina Eramo; Bilal Said; Marc Oriol; Hugo Bruneliere; Sergio Morales, "An architecture for model-based and intelligent automation in DevOps," *Journal of Systems and Software*, 2024, doi: 10.1016/j.jss.2024.112180.
- [34] Gustav Kånåhols; Shahriar Hasan; Per Erik Strandberg, "Integrating Time Series Anomaly Detection Into DevOps Workflows," *IEEE Access*, 2025, doi: 10.1109/access.2025.3550665.
- [35] Johannes Grohmann; Patrick K. Nicholson; Jesus Omana Iglesias; Samuel Kounev; Diego Lugones, "Monitorless: Predicting Performance Degradation in Cloud Applications with Machine Learning," in conference/workshop venue not preserved in canonical screening metadata, 2019, doi: 10.1145/3361525.3361543.
- [36] Dipanwita Guhathakurta; Pooja Aggarwal; Seema Nagar; Rohan Arora; Bing Zhou, "Utilizing Persistence for Post Facto Suppression of Invalid Anomalies Using System Logs," in 2022 IEEE/ACM 44th International Conference on Software Engineering: New Ideas and Emerging Results (ICSE-NIER), 2022, doi: 10.1145/3510455.3512774.
- [37] Jafar Ababneh; Esam Y. A. Al-Nsour; Ala'a Al-Shaikh; Mohammad Rasmi Al-Mousa; Ahmad Al-Zabin; Mahmoud Asassfeh; Hasan Abualese, "Enhancing DevOps Continuous Monitoring Phase: Hybrid Intrusion Detection and Ensemble Learning System (HIDELS)," *IEEE Access*, 2026, doi: 10.1109/access.2026.3650793.
- [38] Dharmeeeka Jeyam; Anna Wiedemann; Gerhard Schwabe; Kadircan Güney, "'Still in the Loop': Coping with Technostress in DevOps Teams and the Impact of GenAI," in conference/workshop venue not preserved in canonical screening metadata, 2026, doi: 10.1145/3786583.3786899.
- [39] Adam Jordan; Yong Chen, "Security Anomaly Detection in Enterprise GitHub," in conference/workshop venue not preserved in canonical screening metadata, 2024, doi: 10.1145/3626203.3670591.
- [40] Yingzhe Lyu; Gopi Krishnan Rajbahadur; Dayi Lin; Boyuan Chen; Zhen Ming (Jack) Jiang, "Towards a Consistent Interpretation of AIOps Models," *ACM Transactions on Software Engineering and Methodology (TOSEM)*, 2021, doi: 10.1145/3488269.
- [41] Subrahmanya Vinayak Joshi; Sergey Serebryakov; Deepak Nanjundiah; Tejas Hegde, "AIOps and Sustainability: Transforming Data Centers for a Greener Future," in SC24-W: Workshops of the International Conference for High Performance Computing, Networking, Storage and Analysis, 2024, doi: 10.1109/scw63240.2024.00234.
- [42] Md Asif Khan; Akramul Azim; Ramiro Liscano; Kevin Smith; Qasim Tauseef; Gkerta Seferi; Yee-Kang Chang, "Machine Learning-based Test Case Prioritization using Hyperparameter Optimization," in conference/workshop venue not preserved in canonical screening metadata, 2024, doi: 10.1145/3644032.3644467.

- [43] Yichen Li; Xu Zhang; Shilin He; Zhuangbin Chen; Yu Kang; Jinyang Liu; Liqun Li; Yingnong Dang; Feng Gao; Zhangwei Xu; Saravan Rajmohan; Qingwei Lin; Dongmei Zhang; Michael R. Lyu, "An Intelligent Framework for Timely, Accurate, and Comprehensive Cloud Incident Detection," in ACM SIGOPS Operating Systems Review, 2022, doi: 10.1145/3544497.3544499.
- [44] Mohamed Samir; Khaled T. Wassif; Soha H. Makady, "Proactive Auto-Scaling Approach of Production Applications Using an Ensemble Model," IEEE Access, 2023, doi: 10.1109/access.2023.3256302.
- [45] Yingzhe Lyu; Heng Li; Zhen Ming (Jack) Jiang; Ahmed E. Hassan, "On the Model Update Strategies for Supervised Learning in AIOps Solutions," ACM Transactions on Software Engineering and Methodology, 2024, doi: 10.1145/3664599.
- [46] Cong Pan; Michael Pradel, "Continuous test suite failure prediction," in conference/workshop venue not preserved in canonical screening metadata, 2021, doi: 10.1145/3460319.3464840.
- [47] Stefano Dalla Palma; Dario Di Nucci; Fabio Palomba; Damian A. Tamburri, "Within-Project Defect Prediction of Infrastructure-as-Code Using Product and Process Metrics," IEEE Transactions on Software Engineering, 2022, doi: 10.1109/tse.2021.3051492.
- [48] Rahul Kapoor; Miray Kas, "Breaking the Observability Tax: Dynamic Resolution Anomaly Detection via Topology-Aware Active LLM Agents," IEEE Access, 2026, doi: 10.1109/access.2026.3675074.
- [49] Hafiz Arslan Ramzan; Kamrul Islam; Md Ahabab Hussain; Raiyan Muntasir Monim; Sabit Md Asad; Sadia Ramzan, "Data-Driven Test Case Prioritization (DD-TCP): A Machine Learning Framework for Intelligent Software Quality Assurance," Computers, Materials and Continua, 2026, doi: 10.32604/cmc.2026.077782.
- [50] Salman Ahmed; Muskaan Singh; Brendan Doherty; Effirul Ramlan; Kathryn Harkin; Magda Bucholc; Damien Coyle, "Knowledge-based Intelligent System for IT Incident DevOps," in 2023 IEEE/ACM International Workshop on Cloud Intelligence & AIOps (AIOps), 2023, doi: 10.1109/aio59134.2023.00005.
- [51] Soeren Becker; Florian Schmidt; Anton Gulenko; Alexander Acker; Odej Kao, "Towards AIOps in Edge Computing Environments," in 2020 IEEE International Conference on Big Data (Big Data), 2020, doi: 10.1109/bigdata50022.2020.9378038.
- [52] Sabbir M. Saleh; Ibrahim Mohammed Sayem; Nazim Madhavji; John Steinbacher, "Advancing Software Security and Reliability in Cloud Platforms through AI-based Anomaly Detection," in conference/workshop venue not preserved in canonical screening metadata, 2024, doi: 10.1145/3689938.3694779.
- [53] Yuqing Wang; Mika V. Mäntylä; Serge Demeyer; Mutlu Beyazıt; Joanna Kisaakye; Jesse Nyssölä, "Cross-System Categorization of Abnormal Traces in Microservice-Based Systems via Meta-Learning," Proceedings of the ACM on Software Engineering, 2025, doi: 10.1145/3715742.
- [54] Hang Su; Qian He; Biao Guo, "KPI anomaly detection method for Data Center AIOps based on GRU-GAN," in conference/workshop venue not preserved in canonical screening metadata, 2022, doi: 10.1145/3485314.3485323.
- [55] N. Sujatha; Latha Narayanan Valli; E. Joice Rathinam; Lokesh V. S.; Mukul Mech, "A Case Study of AIOps in Large Enterprises Using Predictive Analytics for IT Operations," in conference/workshop venue not preserved in canonical screening metadata, 2024, doi: 10.1145/3647444.3647911.
- [56] Arthur Vitui; Tse-Hsun (Peter) Chen, "LLM Agents for AIOps in Kubernetes: An Industrial Experience Report with Red Hat OpenShift," in conference/workshop venue not preserved in canonical screening metadata, 2026, doi: 10.1145/3803437.3805240.
- [57] Guoqing Wang; Zeyu Sun; Yizhou Chen; Yifan Zhao; Qingyuan Liang; Dan Hao, "Commit Artifact Preserving Build Prediction," in conference/workshop venue not preserved in canonical screening metadata, 2024, doi: 10.1145/3650212.3680356.
- [58] Jiabo Wang; Guojun Chu; Jingyu Wang; Haifeng Sun; Qi Qi; Yuanyi Wang; Ji Qi; Jianxin Liao, "LogExpert: log-based Recommended Resolutions Generation using Large Language Model," in 2024 IEEE/ACM 46th International Conference on Software Engineering: New Ideas and Emerging Results (ICSE-NIER), 2024, doi: 10.1145/3639476.3639773.
- [59] Haoyu Wang et al., "DualLane: Fast and Reliable LLM Agents for Interactive AIOps via Dual-Path Planning," in conference/workshop venue not preserved in canonical screening metadata, 2026, doi: 10.1145/3770855.3818380.
- [60] Bohan Liu; He Zhang; Lanxin Yang; Liming Dong; Haifeng Shen; Kaiwen Song, "An Experimental Evaluation of Imbalanced Learning and Time-Series Validation in the Context of CI/CD Prediction," in conference/workshop venue not preserved in canonical screening metadata, 2020, doi: 10.1145/3383219.3383222.
- [61] Chongyang Liu; Shuai Yuan; Yu Zheng; Jia Su, "Fault Prediction in Large-Scale Cluster Environments Based on Improved TCN and DenseNet," in conference/workshop venue not preserved in canonical screening metadata, 2025, doi: 10.1145/3727648.3727802.
- [62] Md Asif Khan; Akramul Azim; Ramiro Liscano; Kevin Smith; Yee-Kang Chang; Gkerta Seferi; Qasim Tauseef, "On the Effectiveness of Feature Selection Techniques in the Context of ML-Based Regression Test Prioritization," IEEE Access, 2024, doi: 10.1109/access.2024.3459656.
- [63] Mingxu Jin; Aoran Lv; Yuanpeng Zhu; Zijiang Wen; Yubin Zhong; Zexin Zhao; Jiang Wu; Hejie Li; Hanheng He; Fengyi Chen, "An Anomaly Detection Algorithm for Microservice Architecture Based on Robust Principal Component Analysis," IEEE Access, 2020, doi: 10.1109/access.2020.3044610.

- [64] Guangyuan Piao; Patrick K. Nicholson; Diego Lugones, "Env2Vec: accelerating VNF testing with deep learning," in conference/workshop venue not preserved in canonical screening metadata, 2020, doi: 10.1145/3342195.3387525.
- [65] Yingzhe Lyu; Heng Li; Mohammed Sayagh; Zhen Ming (Jack) Jiang; Ahmed E. Hassan, "An Empirical Study of the Impact of Data Splitting Decisions on the Performance of AIOps Solutions," *ACM Transactions on Software Engineering and Methodology (TOSEM)*, 2021, doi: 10.1145/3447876.
- [66] Zhaowen Wang; Yong Zhou; YangSiyu Zhang; Fengyu Cong; Dongdong Zhou; Zhijian An, "PA-Rank: A GAN and Reinforcement Learning Powered Framework for Multimetric Anomaly Detection and Causal Diagnosis," *IEEE Internet of Things Journal*, 2025, doi: 10.1109/jiot.2025.3567091.